

Разделение способности студента и сложности предмета в байесовской модели успеваемости

М. Рубанов, Д. Алешков, В. Лавренчук, Д. Ерзиков

Новосибирский государственный университет

Аннотация. Средний балл не различает вклад подготовки студента и вклад сложности предмета. В работе рассматривается байесовская модель, разделяющая эти два вклада по одной лишь матрице оценок: каждому студенту сопоставляется латентная способность, каждому предмету — латентная сложность, а вероятности оценок четырёхбалльной шкалы выражаются через скаляр их совпадения. Исходная постановка, где исход сдачи бинарен, распространена на порядковую шкалу; для сложности предмета предложен приор, выводимый из формы эмпирического распределения его оценок. Сопоставлены три формулы совпадения и четыре способа задать вероятности оценок. Показано, что исходное семейство функций систематически смещает маргинальное распределение оценок, а замена его порядковой логистической моделью со свободными порогами смещение устраняет; при этом свободные пороги порождают ненаблюдаемость, снимаемую закреплением начала отсчёта. Конфигурации сравниваются по PSIS-LOO, выборочной предсказательной точности и апостериорной предиктивной проверке на данных двух семестров (138 студентов, 6 и 10 предметов).

Ключевые слова: байесовский вывод, латентные переменные, порядковая регрессия, MCMC, PSIS-LOO, идентифицируемость.

1 Введение

Средний балл сравнивает студентов, учившихся на разных предметах, как если бы предметы были одинаковы. Пятёрка по курсу, где пятёрки получили все, и четвёрка по курсу, где преобладают тройки, входят в него с одним и тем же весом, хотя стоят за ними разные вещи. Задача состоит в том, чтобы разделить эти два вклада: по одной лишь матрице оценок оценить две латентные величины — способность студента $s \in [0, 1]$ и сложность предмета $d \in [0, 1]$.

Ни одна из них не наблюдается напрямую; наблюдаются только оценки, в которых обе величины смешаны. Разделение возможно потому, что каждый студент сдаёт несколько предметов, а каждый предмет сдают многие студенты: избыточность такой сетки и позволяет отделить свойство студента от свойства предмета.

1.1 Содержание работы

Отправной точкой послужила модель, в которой учебное направление представлено взвешенным двудольным графом, а исход сдачи бинарен: студент либо получил зачёт, либо нет. По отношению к ней сделано следующее.

Постановка распространена с бинарного исхода на порядковую шкалу из четырёх градаций. Это потребовало заменить единственную вероятность вектором из четырёх, монотонно связанным со скаляром совпадения, и сравнить несколько способов такой замены.

Для сложности предмета предложен приор, центр которого выводится из формы эмпирического распределения его оценок, тогда как ранее приоры были одинаковы для всех предметов.

Сопоставлены четыре способа задать вероятности оценок и установлено, что исходное семейство функций систематически смещает маргинальное распределение; замена его порядковой логистической моделью со свободными порогами смещение устраняет. Показано, что свободные пороги порождают ненаблюдаемость, и указано снимающее её ограничение.

Введена процедура проверки — диагностика сходимости, сравнение конфигураций по PSIS-LOO и апостериорная предиктивная проверка, — тогда как ранее работоспособность оценивалась сопоставлением с простыми статистиками на диагностических графиках.

Отметим, что рассматриваемая модель по своей структуре близка к моделям латентных признаков, применяемым в тестологии, где вероятность исхода также определяется соотношением характеристики испытуемого и характеристики задания. Такое сходство здесь не использовалось как исходная посылка: модель строилась от постановки задачи, а не выводилась из существующей традиции.

Дальнейшее изложение построено так. В Раздел 2 вводятся обозначения и формализуется постановка. Раздел 3 описывает модель: вероятностную схему, три формулы совпадения, четыре способа задать вероятности оценок и вопрос идентифицируемости. Раздел 4 посвящён приору на сложность, Раздел 5 — вычислительной схеме, Раздел 6 — процедуре проверки. Результаты собраны в Раздел 7, ограничения работы — в Раздел 9.

2 Постановка задачи

Учебное направление представляется взвешенным двудольным графом. Вершины одной доли — студенты, другой — предметы; ребро существует, если студент сдавал предмет, а его вес равен полученной оценке. Отсутствие ребра означает, что предмет не сдавался, и в правдоподобие такая пара не входит.




Рис. 1: Двудольный граф. Вес ребра m_{ij} — оценка студента s_i за предмет c_j .
Студент s_2 предмет c_2 не сдавал, ребра нет.

Обозначим через $M = \{m_{ij}\}$ матрицу оценок, $m_{ij} \in \{2, 3, 4, 5\}$, и через Ω множество пар с наблюждённой оценкой. Требуется по M оценить векторы $\vec{s} = (s_1, \dots, s_N)$ и $\vec{d} = (d_1, \dots, d_K)$.

Существенно, что содержательный смысл имеет прежде всего **порядок**: какие предметы сложнее и какие студенты сильнее. Сопоставлять абсолютные значения s и d между собой не требуется, и это обстоятельство будет важно при обсуждении идентифицируемости (Раздел 3.4).

2.1 Данные

Рассматриваются две матрицы оценок за первый и второй семестры одного направления подготовки: 138 студентов, 6 и 10 предметов соответственно. Матрицы разрежены — не всякий студент сдавал всякий предмет, — и пропуски трактуются как отсутствие ребра, а не как нулевая оценка. Данные обезличены: строки индексированы порядковым номером.

Результатом оценивания является апостериорное распределение, а не точечная оценка, — доступно не только значение, но и мера его определённости данными.

3 Модель

Модель строится в два слоя. Сначала пара (s_i, d_j) сворачивается в один скаляр совпадения $r_{ij} \in [0, 1]$, затем из этого скаляра получается распределение на четырёх оценках. Такое разделение позволяет менять две части независимо, чем проект и пользуется: реализованы три формулы совпадения и четыре семейства правдоподобия, сравнимые между собой.

3.1 Вероятностная постановка

Полная модель задаётся приорами и правдоподобием:

$$s_i \sim \text{Beta}(2, 2), \quad d_j \sim \text{Beta}(\alpha_j, \beta_j), \quad m_{ij} \mid s_i, d_j \sim \text{Categorical}(\pi(r_{ij})), \quad (1)$$

где $\pi(r) = (\pi_2(r), \pi_3(r), \pi_4(r), \pi_5(r))$ — вектор вероятностей оценок. В предположении независимости оценок при известных латентных величинах апостериорное распределение факторизуется:

$$p(\vec{s}, \vec{d} \mid M) \propto \underbrace{\prod_{(i,j) \in \Omega} \pi_{m_{ij}}(r_{ij})}_{\text{правдоподобие}} \cdot \underbrace{\prod_{i=1}^N p(s_i) \prod_{j=1}^K p(d_j)}_{\text{приоры}}. \quad (2)$$

Произведение в правдоподобии берётся только по наблюдаемым парам, поэтому пропуски обрабатываются естественно и не требуют импутации. Нормировочная константа в формуле (2) неизвестна, что и вынуждает обращаться к методам Монте-Карло (Раздел 5).

Концентрация приора на сложность фиксирована: $\alpha_j + \beta_j = 4$, что соответствует «силе» приора $\text{Beta}(2, 2)$. Меняется только его центр $\alpha_j / (\alpha_j + \beta_j)$, и меняется он по данным.

3.2 Формулы совпадения

Скаляр r выражает, насколько студент «соответствует» предмету. Реализованы три варианта, выбираемые параметром `ratio_kind`:

вариант	формула	свойства
legacy_sd	$r = \frac{s}{s+d}$	симметрична по $s \leftrightarrow d$; при $s = d$ равна $1/2$
current	$r = 1 - d(1 - s)$	асимметрична: равна 1 и при $d = 0$, и при $s = 1$
sigmoid	$r = \sigma(k(s - d)), k = 5$	симметрична, гладкая; k задаёт резкость перехода

Первые две взяты из исходной статьи, третья добавлена здесь. Для `sigmoid` принято $\sigma(z) = (1 + e^{-z})^{-1}$.

Про `legacy_sd` в статье доказано, что в бинарном случае она вырождается. Действительно, при $m \sim \text{Bernoulli}(s/(s + d))$ логарифм правдоподобия принимает вид

$$\log p(M \mid \vec{s}, \vec{d}) = \sum_i M_i \log s_i + \sum_j C_j \log d_j - \sum_{(i,j) \in \Omega} \log(s_i + d_j), \quad (3)$$

где M_i — число сданных студентом предметов, а C_j — число не сдавших данный предмет. Последнее слагаемое не зависит от исхода, поэтому правдоподобие определяется лишь **количеством** сданного, но не тем, какие именно предметы сданы: студент, сдавший два лёгких предмета, и студент, сдавший два трудных, неразличимы. Статья на этом основании отвергает формулу.

Для четырёхуровневой шкалы это рассуждение не переносится напрямую — оценка несёт больше информации, чем факт сдачи, — однако формула сохранена как база сравнения, а не как рабочий вариант.

Проверить формулы удобно по характерным точкам:

s	d	сценарий	ожидание
0	1	слабый студент, сложный предмет	2
0.5	0.5	средний студент, средний предмет	3–4
1	0	сильный студент, лёгкий предмет	5
0	0	слабый студент, лёгкий предмет	3–4
1	1	сильный студент, сложный предмет	3–4

legacy_sd и sigmoid этим ожиданиям отвечают. current — нет: подстановка даёт $r(0, 0) = 1 - 0 \cdot 1 = 1$ и $r(1, 1) = 1 - 1 \cdot 0 = 1$, то есть слабый студент на лёгком предмете и сильный на трудном отображаются в одну точку, и обоим уверенно предсказывается пятёрка. Кроме того $r(0.5, 0.5) = 0.75$ вместо ожидаемого $1/2$, отчего средний студент на среднем предмете получает $\mathbb{E}[\text{оценка}] \approx 4.24$.

3.3 Семейства правдоподобия

Способ перехода от r к вектору $\pi(r)$ выбирается параметром --model; реализованы четыре варианта.

3.3.1 Фиксированное семейство: nocond

Исходный вариант задаёт вероятности четырьмя явными функциями:

$$\begin{aligned} f_2(x) &= \frac{(1-x)^3}{(1-x)^3 + 10x^2}, & f_5(x) &= f_2(1-x), \\ f_3(x) &= (1-x)(1-f_2(x)-f_5(x)), & f_4(x) &= f_3(1-x), \end{aligned} \quad (4)$$

и полагает $\pi(r) = (f_2(r), f_3(r), f_4(r), f_5(r))$.

Семейство нормировано по построению, и это стоит проверить явно. Из $f_5(x) = f_2(1-x)$ следует $f_5(1-x) = f_2(x)$, поэтому

$$f_4(x) = f_3(1-x) = (1-(1-x))(1-f_2(1-x)-f_5(1-x)) = x(1-f_2(x)-f_5(x)). \quad (5)$$

Складывая с $f_3(x) = (1-x)(1-f_2(x)-f_5(x))$, получаем

$$f_3(x) + f_4(x) = [(1-x) + x](1-f_2(x)-f_5(x)) = 1-f_2(x)-f_5(x), \quad (6)$$

откуда $f_2 + f_3 + f_4 + f_5 \equiv 1$ при любом x . Отдельная нормировка не требуется; множители $(1-x)$ и x лишь делят остаток $1-f_2-f_5$ между тройкой и четвёркой, смещая его к низким и высоким x соответственно.

Всё семейство симметрично относительно $x = 1/2$ в том смысле, что замена $x \leftrightarrow 1-x$ переставляет оценки: $2 \leftrightarrow 5$ и $3 \leftrightarrow 4$. Это свойство удобно, но оно же ограничивает форму получаемого маргинального распределения — обстоятельство, которое проявится при проверке (Раздел 6.3).

3.3.2 С гейтом крайних оценок: cond

Поверх фиксированного семейства добавляется смесь, смещающая уверенные случаи к крайним оценкам:

$$\pi(r) = p_5 \cdot e_5 + p_2 \cdot e_2 + (1-p_5-p_2) \cdot f(r), \quad (7)$$

где $e_5 = (0.001, 0.001, 0.001, 0.997)$, $e_2 = (0.997, 0.001, 0.001, 0.001)$ — почти вырожденные распределения, а веса задаются сигмоидами $p_5 = \sigma(t(r - \text{hi}))$ и $p_2 = \sigma(t(\text{lo} - r))$. По умолчанию $\text{lo} = 0.3$, $\text{hi} = 0.7$, $t = 15$.

Поскольку при $\text{lo} < \text{hi}$ обе сигмоиды одновременно велики быть не могут, выполняется $p_5 + p_2 \leq 1$, и формула (7) действительно задаёт выпуклую комбинацию трёх распределений.

Пороги смещены внутрь шкалы намеренно. При «естественных» значениях 0.1 и 0.9 гейт активен лишь там, где f -функции и без него дают 0.997, так что `cond` численно не отличается от `poscond`: расхождение проявляется в третьем знаке.

3.3.3 Свободные веса оценок: `tilted`

Форма f_k сохраняется, но домножается на свободные веса:

$$\pi_k(r) = \frac{w_k f_k(r)}{\sum_l w_l f_l(r)}, \quad w \sim \text{Dirichlet}(1, 1, 1, 1). \quad (8)$$

Три дополнительных параметра (четыре веса минус нормировка) задают распространённость каждой оценки независимо от r . Зависимость от r при этом не меняется, меняется лишь базовый уровень.

3.3.4 Порядковая логистическая: `ordered`

Здесь фиксированное семейство заменяется целиком. Полагая $z = \text{logit}(r)$ и вводя пороги $c_1 < c_2 < c_3$, определяем

$$\Pr(\text{оценка} \leq k) = \sigma(c_k - z), \quad k = 2, 3, 4, \quad (9)$$

откуда $\pi_2 = \sigma(c_1 - z)$, $\pi_3 = \sigma(c_2 - z) - \sigma(c_1 - z)$, $\pi_4 = \sigma(c_3 - z) - \sigma(c_2 - z)$ и $\pi_5 = 1 - \sigma(c_3 - z)$. Упорядоченность порогов гарантирует неотрицательность всех четырёх вероятностей, а их сумма равна единице телескопически.

В отличие от (4) форма распределения здесь не задана заранее: пороги настраиваются по данным, оставляя монотонную связь с z неизменной. Именно эта свобода и позволяет модели воспроизвести наблюдаемые доли оценок, чего фиксированное семейство сделать не в состоянии.

3.4 Идентифицируемость

Свободные пороги в (9) приводят к ненаблюдаемости, которую необходимо снять явно. Для `ratio_kind = "sigmoid"` имеем $r = \sigma(k(s - d))$, следовательно

$$z = \text{logit}(\sigma(k(s - d))) = k(s - d), \quad (10)$$

и правдоподобие (9) зависит от параметров только через разность $c_k - k(s_i - d_j)$. Рассмотрим преобразование

$$c_k \rightarrow c_k + \delta, \quad s_i \rightarrow s_i + \frac{\delta}{k}, \quad d_j \rightarrow d_j. \quad (11)$$

Тогда $c_k + \delta - k(s_i + \delta/k - d_j) = c_k - k(s_i - d_j)$: все вероятности сохраняются, а значит правдоподобие постоянно вдоль одномерного направления в пространстве параметров. Апостериорное распределение вырождается в почти плоский хребет, удерживаемый лишь приорами, и цепи расходятся: на семестре 2 это давало $\hat{R} = 1.53$ при $\text{ESS} = 8$.

Направление устраняется закреплением начала отсчёта. Средний порог фиксируется, $c_2 = 0$, а свободными остаются два зазора:

$$c_1 = -g_1, \quad c_2 = 0, \quad c_3 = g_2, \quad g_1, g_2 \sim \text{HalfNormal}(2). \quad (12)$$

Выразительность при этом не теряется — общий уровень строгости поглощается латентными s и d , — а сходимость восстанавливается: $\hat{R} = 1.003$, $\text{ESS} = 1304$, дивергенций нет.

Отметим, что более слабая неопределённость присутствует и во всех остальных вариантах: сдвиг $(s_i + \delta, d_j + \delta)$ оставляет $k(s_i - d_j)$ неизменным. Здесь её удерживают бета-приоры, ограничивающие обе величины отрезком $[0, 1]$, и потому отдельного вмешательства не требуется. Замечание об идентифицируемости в исходной статье относится к той же природе: там показано, что уравнения градиента имеют единственное решение по каждой группе переменных при фиксированной другой,

но единственность по системе в целом не установлена, и байесовская постановка нужна в том числе для существования решения.

4 Chi-square приор на сложность

Плоский Beta(2, 2) для всех предметов игнорирует то, что видно из данных сразу: у сложного предмета распределение оценок имеет иную форму, чем у лёгкого. Эту информацию разумно передать модели через приор.

Пусть $e_j = (e_{j2}, e_{j3}, e_{j4}, e_{j5})$ — эмпирические доли оценок по предмету j , а ρ^l и ρ^c — два эталонных распределения, отвечающих заведомо лёгкому и заведомо трудному предмету. Введём расстояние χ^2 между дискретными распределениями

$$\chi^2(e, \rho) = \sum_{k=2}^5 \frac{(e_k - \rho_k)^2}{\rho_k} \quad (13)$$

и определим оценку сложности как относительную близость к трудному эталону:

$$\text{score}_j = \frac{\chi^2(e_j, \rho^l)}{\chi^2(e_j, \rho^l) + \chi^2(e_j, \rho^c)} \in [0, 1]. \quad (14)$$

Величина равна нулю, когда распределение совпадает с эталоном лёгкого предмета, и единице при совпадении с трудным. Она и становится центром приора при фиксированной концентрации $c = 4$:

$$\alpha_j = c \cdot \text{score}_j, \quad \beta_j = c \cdot (1 - \text{score}_j). \quad (15)$$

Результат согласуется с содержательными ожиданиями: гуманитарные предметы получают оценку 0.02–0.05, математический анализ и аналитическая геометрия — 0.87–0.91. Существенно, что приор влияет на центр, но не на жёсткость: при $c = 4$ данных достаточно, чтобы апостериорное распределение заметно отклонилось от него, если эмпирика того требует.

5 Вывод

Нормировочная константа в (2) недоступна аналитически, поэтому апостериорное распределение исследуется методом Монте-Карло по схеме марковской цепи. Используется алгоритм NUTS^[1] — самонастраивающийся вариант гамильтонова метода, не требующий ручного подбора длины траектории. Модель описана средствами PyMC^[5] считаются все комбинации семейств, формул совпадения и семестров.

Сэмплирование выполняется бэкендом nutpie, компилирующим модель через numba. Родной бэкенд PyTensor требует C++-компилятора; без него граф выполняется интерпретатором Python, и время одной трассы возрастает с десятков секунд до величин, непригодных для работы.

5.1 Диагностика сходимости

Монте-Карло даёт выборку из апостериорного распределения лишь при условии, что цепи сошлись, и это условие подлежит проверке. Используются три показателя: $\hat{R}$ в ранговой модификации^[4] — мера согласия между цепями, близкая к единице при их совпадении; ESS — эффективный размер выборки с поправкой на автокорреляцию; число дивергенций — расхождений численного интегратора, указывающих на трудную геометрию. Приняты пороги $\hat{R} \leq 1.01$ и $\text{ESS} \geq 400$. Диагностики вычислены средствами ArviZ^[6].

сем	модель	ratio	$\hat{R}$ (s)	ESS (s)	$\hat{R}$ (d)	ESS (d)	див.	вердикт
1	cond	legacy_sd	1.001	12036	1.001	4730	0	ОК
1	cond	current	1.002	4766	1.006	761	0	ОК

1	cond	sigmoid	1.003	1940	1.009	587	0	OK
1	nocond	legacy_sd	1.001	14704	1.001	9410	0	OK
1	nocond	current	1.001	10167	1.003	1580	0	OK
1	nocond	sigmoid	1.002	16392	1.001	2248	0	OK
1	tilted	sigmoid	1.002	17421	1.001	1078	0	OK
1	ordered	sigmoid	1.002	15316	1.005	1309	0	OK
2	cond	legacy_sd	1.001	9911	1.002	4365	0	OK
2	cond	current	1.002	3106	1.005	927	0	OK
2	cond	sigmoid	1.003	1332	1.007	512	0	OK
2	nocond	legacy_sd	1.002	13032	1	8193	0	OK
2	nocond	current	1.001	12349	1.001	1878	0	OK
2	nocond	sigmoid	1.002	4504	1.004	1266	0	OK
2	tilted	sigmoid	1.001	3154	1.025	120	0	r_hat>1.01: 4; ESS<400: 10
2	ordered	sigmoid	1.001	14332	1.003	1304	0	OK

Дивергенций нет ни в одной конфигурации, то есть геометрия задачи для NUTS приемлема, а возникающие трудности носят характер медленного перемешивания и устраняются числом итераций. Тяжелее всего сходится `sigmoid`, причём расходится не способность студентов, а сложность предметов: параметров мало, наблюдений на каждый много, апостериорное распределение узкое.

6 Валидация

Сходимость подтверждает лишь корректность работы сэмплера и ничего не говорит о том, насколько модель соответствует данным. Это проверяется тремя независимыми способами, отвечающими на разные вопросы.

6.1 PSIS-LOO

Первый вопрос: какая конфигурация лучше предсказывает наблюдения вне выборки. Прямая кросс-валидация с исключением по одному потребовала бы переобучения модели для каждого из сотен наблюдений. PSIS-LOO^[2] получает ту же величину из одной подгонки, опираясь на тождество

$$p(\theta | y_{-i}) \propto \frac{p(\theta | y)}{p(y_i | \theta)}, \quad (16)$$

из которого следует, что математическое ожидание по постериору без наблюдения i выражается через взвешивание уже имеющихся draws с весами $w_i^{(t)} = 1/p(y_i | \theta^{(t)})$. Эти веса имеют тяжёлый хвост, поэтому хвост аппроксимируется обобщённым распределением Парето и сглаживается^[3]. Итоговая величина

$$\text{elpd}_{\text{LOO}} = \sum_i \log p(y_i | y_{-i}) \quad (17)$$

оценивает предсказательную плотность; чем она выше, тем лучше.

Параметр формы подогнанного хвоста, Парето- k , служит диагностикой самой аппроксимации: при $k > 0.7$ веса слишком тяжелы, и оценка для этого наблюдения не гарантирована. Число таких точек приведено отдельной колонкой.

Сравнение проводится отдельно по каждому семестру: `elpd` есть сумма по наблюдениям, и величины по выборкам разного размера несопоставимы.

Семестр 1

Семестр 2

конфигурация	elpd	diff	dse	k>0.7	конфигурация	elpd	diff	dse	k>0.7
tilted_sigmoid	-611.3	0	0	10	ordered_sigmoid	-974.7	0	0	2
nocond_current	-625.9	14.6	9	12	nocond_current	-977.8	3	9.9	7
nocond_sigmoid	-630.6	19.3	7	7	tilted_sigmoid	-983.4	8.6	9.7	6
ordered_sigmoid	-637.6	26.3	9.1	2	nocond_sigmoid	-992.9	18.2	11.4	6
cond_current	-656	44.7	9.8	18	cond_current	-1005.5	30.7	11.7	10
cond_sigmoid	-661.6	50.3	9.3	14	cond_legacy_sd	-1013.8	39.1	9.6	3
nocond_legacy_sd	-663.1	51.8	11.8	3	nocond_legacy_sd	-1015.9	41.1	9.2	1
cond_legacy_sd	-664.7	53.4	10.3	7	cond_sigmoid	-1018.3	43.5	13.3	8

Сопоставлять следует не сами elpd, а разность diff с её стандартной ошибкой dse; разрыв считается значимым, если превышает несколько dse. Отсюда следуют два вывода. Гейт снижает предсказательную способность: все конфигурации с cond уступают своим аналогам без гейта с отрывом порядка 30–44 elpd при dse 9–13, то есть на три-четыре стандартные ошибки. В то же время между ведущими конфигурациями разрывы меньше двух dse — данные их не разделяют, и выбор между ними по одному этому критерию был бы произволен.

6.2 Точность на наблюдаемых оценках

Второй вопрос: что модель выдаёт непосредственно. Считаются те же вероятности, которые печатает `query.py`, с маргинализацией по постериору:

$$\hat{\pi}_k = \frac{1}{T} \sum_{t=1}^T \pi_k \left(r \left(s_i^{(t)}, d_j^{(t)} \right) \right), \quad (18)$$

то есть усредняется вектор вероятностей по draws, а не подставляются апостериорные средние параметров. По полученным $\hat{\pi}$ вычисляются средняя логарифмическая плотность на фактических оценках, доля совпадений наиболее вероятной оценки с фактической и средняя абсолютная ошибка ожидаемой оценки.

Метрики выборочные — модель эти наблюдения видела, — поэтому они дополняют LOO, но не заменяют его.

сем	модель	ratio	log pred	точность	MAE
1	tilted	sigmoid	-0.7128	0.6989	0.4236
1	nocond	sigmoid	-0.7547	0.6676	0.4257
1	nocond	current	-0.7705	0.6747	0.4445
1	cond	sigmoid	-0.8038	0.6634	0.4212
1	ordered	sigmoid	-0.8076	0.6705	0.5012
1	cond	current	-0.8138	0.6463	0.4428
1	nocond	legacy_sd	-0.8378	0.5256	0.5079
1	cond	legacy_sd	-0.8459	0.5994	0.4886
2	tilted	sigmoid	-0.8195	0.6509	0.4788
2	nocond	sigmoid	-0.8361	0.617	0.48
2	nocond	current	-0.8433	0.6161	0.4887
2	ordered	sigmoid	-0.8588	0.6373	0.5143
2	cond	sigmoid	-0.8703	0.5977	0.484
2	cond	current	-0.8744	0.6044	0.4912
2	nocond	legacy_sd	-0.8864	0.5387	0.5346

2	cond	legacy_sd	-0.8934	0.5919	0.5228
---	------	-----------	---------	--------	--------

Порядок первых мест расходится с LOO, что согласуется с величиной dse: когда конфигурации статистически неразличимы, знак разницы между ними зависит от выбранной метрики.

6.3 Posterior predictive check

Третий вопрос наиболее прямой: похожи ли данные, порождённые моделью, на настоящие. Из апостериорного распределения разыгрываются новые комплекты оценок, $\tilde{y}^{(t)} \sim p(y \mid \theta^{(t)})$, и распределение получившихся долей сравнивается с фактическим. Проверяется попадание фактической доли каждой оценки в 94-процентный интервал модели.

сем	оценка	факт	модель	интервал, ниж.	интервал, верх.	попал
1	2	0.0199	0.02	0.0085	0.0348	да
1	3	0.3253	0.3446	0.3068	0.3813	да
1	4	0.2571	0.2568	0.216	0.2975	да
1	5	0.3977	0.3785	0.3388	0.4218	да
2	2	0.0232	0.0227	0.0126	0.0358	да
2	3	0.2795	0.2821	0.2534	0.3148	да
2	4	0.2853	0.287	0.2481	0.3221	да
2	5	0.412	0.4083	0.3772	0.4371	да

Именно эта проверка выявила главный дефект исходного семейства, тогда как обе предыдущие его не заметили.

7 Результаты

7.1 Вырожденный гейт

В первоначальной реализации cond веса гейта нормировались друг на друга:

$$p_5 = \frac{\sigma_5}{\sigma_5 + \sigma_2}, \quad p_2 = \frac{\sigma_2}{\sigma_5 + \sigma_2}, \quad \text{где } \sigma_5 = \sigma(t(r - \text{hi})), \quad \sigma_2 = \sigma(t(\text{lo} - r)). \quad (19)$$

Тогда $p_5 + p_2 \equiv 1$ тождественно, а значит вес третьего слагаемого в (7) равен нулю при любом r , и семейство $f_2..f_5$ не участвует в правдоподобию вообще. Модель вырождалась в смесь двух почти вырожденных распределений: тройка и четвёрка получали вероятность 0.001 независимо от данных и были недостижимы. На середине шкалы, где обе сигмоиды малы и равны, нормировка давала $p_5 = p_2 = 1/2$, то есть распределение (0.499, 0.001, 0.001, 0.499) — выбор между двойкой и пятёркой подбрасыванием монеты.

Нормировка устранена, веса берутся из сигмоид напрямую. Свойство $p_5 + p_2 \leq 1$, необходимое для (7), при $\text{lo} < \text{hi}$ выполняется само.

7.2 Смещение фиксированного семейства

Posterior predictive check показал, что все конфигурации на фиксированном семействе занижают долю троек на 6–10 процентных пунктов и завышают долю двоек в два-четыре раза. Причина в форме самих f -функций: при константах $(1 - x)^3$ и $10x^2$ и симметрии относительно $x = 1/2$ семейство не способно воспроизвести распределение, в котором двоек около двух процентов, а троек около трети. Никакой выбор r этого не исправляет, поскольку ограничение заложено в форме, а не в аргументе.

Оба семейства со свободными параметрами устраняют смещение полностью: tilted и ordered дают по восемь попаданий из восьми против двух у фиксированного.

7.3 Цена гибкости

Добавление свободных параметров, снявшее смещение, одновременно породило ненаблюдаемость, разобранную в Раздел 3.4: модель перестала сходиться, хотя параметров прибавилось всего три. Это иллюстрирует общее обстоятельство — смещение снимается не количеством параметров, а тем, чтобы они были идентифицируемы. Ограничение, закрепляющее начало отсчёта, восстановило сходимость, не сузив класс описываемых распределений.

8 Итоговая конфигурация

По умолчанию используется `ordered` совместно с `sigmoid`. Основания следующие: воспроизведение маргинального распределения оценок, лучшая позиция по LOO на семестре 2 и наиболее надёжная LOO-оценка — два наблюдения с высоким Парето- k против шести и более у остальных конфигураций, — а также сходимость без замечаний на обоих семестрах.

`tilted` превосходит его по выборочным метрикам и по LOO на семестре 1, однако его трасса на семестре 2 не сошлась, а большое число точек с Парето- $k > 0.7$ снижает доверие и к его LOO-оценке. Прочие семейства сохранены и доступны через `--model`, так что сравнение воспроизводимо, а выбор конфигурации остаётся обоснованным решением, а не умолчанием.

8.1 Использование

Запрос к посчитанной модели возвращает апостериорные величины и прогноз оценки для пары «студент — предмет»:

```
python scripts/query.py --sem 1 --student 42 --subject "Высшая алгебра"
```

Студент #42

способность s : 0.337 ± 0.140 94% HDI [0.069, 0.582]

Предмет «Высшая алгебра»

сложность d : 0.471 ± 0.040 94% HDI [0.396, 0.547]

оценка	P	факт
2	0.0431	
3	0.6041	<--
4	0.2356	
5	0.1173	

$E[\text{оценка}] = 3.43$

Распределение вычисляется по формуле (18), поэтому неопределённость в параметрах переносится в прогноз: интервал получается шире, чем дала бы подстановка апостериорных средних, и это отражает реальное состояние знания.

9 Ограничения и дальнейшая работа

Трасса `sem2 · tilted · sigmoid` не сошлась ($\hat{R} = 1.025$, $ESS = 120$); её показатели в сравнении помечены как ненадёжные.

Held-out валидация не проводилась. Все приведённые метрики либо выборочные, либо основаны на LOO, вычисляемом из одной подгонки; прямая проверка на намеренно скрытой части данных дала бы более убедительную оценку обобщающей способности.

Апостериорная предиктивная проверка охватывает только маргинальное распределение оценок. Модель может верно воспроизводить общую долю четвёрок и при этом распределять их не тем студентам; проверка по каждому предмету или студенту в отдельности была бы строже и, вероятно, выявила бы дефекты, незаметные на агрегированном уровне.

Наконец, выводы получены на данных одного направления подготовки за два семестра. Перенос на другие выборки требует отдельной проверки: в частности, эталонные распределения для приора

на сложность (Раздел 4) подбирались под наблюдаемую здесь форму оценок и могут оказаться непригодными там, где шкала используется иначе.

10 Заключение

Рассмотрена байесовская модель, разделяющая вклад подготовки студента и вклад сложности предмета по одной лишь матрице оценок. Исходная постановка, где исход сдачи бинарен, распространена на порядковую шкалу из четырёх градаций; для сложности предмета предложен приор, центр которого выводится из формы эмпирического распределения его оценок.

Сопоставление четырёх семейств правдоподобия показало, что фиксированное семейство, задающее вероятности оценок явными функциями, систематически смещает маргинальное распределение: доля троек занижается на 6–10 процентных пунктов, доля двоек завышается в два-четыре раза. Ограничение заложено в форме функций и не устраняется выбором формулы совпадения. Замена фиксированного семейства порядковой логистической моделью со свободными порогами снимает смещение полностью.

Отдельно установлено, что добавление свободных параметров породило ненаблюдаемость: правдоподобие оказалось постоянным вдоль одномерного направления в пространстве параметров, отчего цепи перестали сходиться. Закрепление начала отсчёта восстановило сходимость, не сузив класс описываемых распределений. Это наблюдение носит общий характер: смещение снимается не количеством параметров, а тем, чтобы они были идентифицируемы.

Три способа проверки — PSIS-LOO, выборочная предсказательная точность и апостериорная предиктивная проверка — дали согласованный, но не совпадающий результат. Первые два не различают ведущие конфигурации статистически, тогда как третий выявил дефект, для обнаружения которого агрегированных мер предсказательной способности оказалось недостаточно. Это подтверждает целесообразность применения нескольких независимых проверок.

Список литературы

- [1] Hoffman M. D., Gelman A. The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo // Journal of Machine Learning Research. 2014. Vol. 15.
- [2] Vehtari A., Gelman A., Gabry J. Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC // Statistics and Computing. [2017] Vol. 27.
- [3] Vehtari A., Simpson D., Gelman A., Yao Y., Gabry J. Pareto Smoothed Importance Sampling // Journal of Machine Learning Research. 2024.
- [4] Vehtari A., Gelman A., Simpson D., Carpenter B., Bürkner P.-C. Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC // Bayesian Analysis. 2021. Vol. 16.
- [5] Abril-Pla O. et al. PyMC: a modern and comprehensive probabilistic programming framework in Python // PeerJ Computer Science. 2023.
- [6] Kumar R., Carroll C., Hartikainen A., Martin O. ArviZ a unified library for exploratory analysis of Bayesian models in Python // Journal of Open Source Software. 2019. Vol. 4.